




Modelovanje moralnih i emocionalnih aspekata jezika u klasifikaciji konverzacijonih tekstova

doktorska disertacija

Milena M. Šošić

Sadržaj

01

Uvod

Slajd 1 - 6

02

Predmet, cilj i hipoteze

Slajd 7 - 8

03

Predložena metodologija

Slajd 9 - 19



04

Resursi za srpski jezik

Slajd 20 - 33

05

Diskusija rezultata

Slajd 34

06

Zaključak


Slajd 35 - 40

Uvod

- Konverzacione poruke predstavljaju nov način razmene informacija u savremenom digitalnom okruženju
- Platforme: društvene mreže, alati elektronske pošte, alati za brzo komuniciranje i automatsko generisanje odgovora
- Metode mašinskog učenja za rešavanje problema klasifikacije
 1. Tradicionalni algoritmi
 2. Algoritmi dubokog učenja
- Napredni pristupi (duboko učenje, veliki jezički modeli) koriste se za analizu ovih složenih aspekata komunikacije
- Modelovanje sekvencijalnih zavisnosti između poruka
- Uključivanje dodatnih atributa – hibridni pristup
- Emocionalni i moralni aspekt jezika uočen je kao važan u razumevanju i klasifikaciji konverzionih poruka na različitim klasifikacionim zadacima
- Prepoznat nedostatak resursa za analizu ovih aspekata srpskog jezika

Konverzacioni tekstovi

- Konverzacioni niz je sekvenca međusobno povezanih poruka
- Struktura poruke - segmenti:
 1. Tekstualni sadržaj
 2. Potpis (jedinствeni identifikator, vremenska odrednica kreiranja, autor, kanal, platforma i drugi)
 3. Veza sa prethodnom porukom u nizu
- Analiza:
 1. Pojedinačna poruka,
 2. Parovi neposrednih poruka,
 3. Konverzacioni niz
- Vrste:
 1. Poruke elektronske pošte
 2. Poruke na društvenim mrežama
 3. Ostale vrste konverzacijonih poruka



Emocije

Emocije su složena psihološka i fiziološka iskustva koja se pokreću različitim unutrašnjim i spoljašnjim stimulansima.

- Teorije o osnovnim emocijama
- Ekmanova kategorizacija emocija – 6 kategorija

Ekman, P. (1994): The nature of emotion: fundamental questions, Oxford University Press


- Plutčikova kategorizacija emocija – 8 kategorija

Plutchik, R. (2001): The nature of emotions: Human emotions have deep evolutionary roots, a fact that may explain their complexity and provide tools for clinical practice, American scientist, 89(4), 344-350

anger, anticipation, disgust, fear, joy, sadness, surprise, trust
(sr. ljutnja, iščekivanje, gađenje, strah, radost, tuga, iznenađenje, poverenje)

- Plutčikov točak emocija, karakteristike:

1. Tri intenziteta,
2. Međukategorije,
3. Sentimentalno suprotstavljene emocije



- Emocionalni leksikoni za engleski jezik: WordNet-Affect, ANEW(XANEW), LIWC, SenticNet, NRC grupa leksikona
- Prebrojavanje ili vrednovanje prepoznatih lema

Moral

- **Teorija o moralnim vrednostima (eng. *Moral Foundations Theory, MFT*)** – <https://moralfoundations.org/> prepoznaje 5 glavnih moralnih vrednosti predstavljenih dihotomnim parovima (vrlina/mana):

care/harm, authority/subversion, fairness/cheating, loyalty/betrayal, purity/degradation
(sr. briga/povreda, autoritet/subverzija, pravednost/varanje, lojalnost/izdaja, svetost/degradacija)

- **Upitnik o moralnim vrednostima (eng. *Moral Foundations Questionnaire, MFQ*)** – sa ukupno 32 pitanja dizajniran je da vrednuje sklonost ispitanika prema moralnim vrednostima
[*Graham, J., Haidt, J. at a. \(2013\). Moral Foundations Theory: The pragmatic validity of moral pluralism. Advances in experimental social psychology, 47, 55-130*](#)
- Teorija je u stalnom naučnom unapređivanju:
 - Drugi kandidati za osnovne moralne vrednosti: sloboda (eng. *liberty*), čast (eng. *honor*), posedovanje (eng. *ownership*)
 - Moralna vrednost pravednost (eng. *fairness*) podeljena je u jednakost (eng. *equality*) + proporcionalnost (eng. *proportionality*)
[*Atari, M., Haidt, J., Graham J., Koleva, S. at a. \(2023\). Morality beyond the WEIRD: How the nomological network of morality varies across cultures. Journal of personality and social psychology, 125\(5\), 1157-1188*](#)
- Koristi se kao standardan pristup u računarskoj lingvistici za kategorizaciju i prepoznavanje moralnih vrednosti u tekstu
- Leksikoni moralnih reči za engleski jezik: MFD, eMFD, MoralStrength

Predmet i cilj istraživanja

Predmet:

- Prepoznavanje i analiza uticaja moralnih i emocionalnih aspekata jezika u zadacima klasifikacije konverzionih tekstova
- Primena matematički zasnovanih metoda za pronalaženje značajnih atributa klasifikacije utvrdiće u kojoj meri moralni i emocionalni atributi uzimaju učešće u ovako utvrđenim skupovima.
- Analiza konverzionih tekstova na engleskom i srpskom jeziku primenom matematički zasnovanih računarskih metoda, i to prvenstveno metoda i algoritama mašinskog učenja, kako tradicionalnih, tako i naprednih metoda dubokog učenja.

Cilj:

- Predlaganje generičkog hibridnog pristupa za klasifikaciju konverzionih tekstova.
- Razvoj novih jezičkih resursa za srpski jezik – leksikona i korpusa sa obeleženim moralnim i emocionalnim kategorijama.
- Pravljenje klasifikacionog modela zasnovanog na algoritmima mašinskog učenja, kao posebno značajnog resursa, za prepoznavanje moralnih i emocionalnih aspekata u tekstovima na srpskom jeziku.
- Utvrđivanje značaja moralnih i emocionalnih aspekata jezika na klasifikaciju pojedinačnih ili nizova konverzionih poruka, kao i utvrđivanje stepena njihove međusobne zavisnosti.

Hipoteze istraživanja

Hipoteza 1

Uključivanje moralnih i emocionalnih aspekata jezika značajno doprinosi tačnosti modela klasifikacije konverzacionih tekstova, što ukazuje na njihov značaj u interpretaciji i razumevanju konverzacionih tekstova.

Hipoteza 2

Kvantitativnom analizom atributa moguće je utvrditi korelaciju između iskazanih moralnih stavova i emocionalnih reakcija u konverzacionim porukama.

Hipoteza 3

Razvijeni semantički leksikoni moralnih i emocionalnih afekata reči za srpski jezik mogu doprineti prepoznavanju ovih aspekata u tekstu.

Hipoteza 4

Moguće je razviti klasifikacione modele prihvatljive tačnosti koji na osnovu karakteristika tekstualnih sadržaja iz razvijenih obeleženih konverzacionih korpusa na srpskom jeziku, mogu da prepoznaju moralne i emocionalne aspekte jezika.


Predložena metodologija klasifikacije

Neophodni eksperimenti u cilju pronalaženja optimalnog:

1. Načina predstavljanja tekstualnog sadržaja u vektorskom obliku
2. Načina normalizacije i tokenizacije teksta
3. Skupa značajnih pridruženih atributa klasifikacije
4. Klasifikacionog algoritma
5. Skupa hiperparametara algoritma

Specifično:


1. Korišćenje specijalno dizajniranih pridruženih (META) atributa
2. Uključivanje mehanizma pažnje (Att) kod algoritama dubokog učenja
3. Doobučavanje velikih jezičkih modela (LLM) na zadatku klasifikacije korišćenjem specijalno dizajniranih skupova instrukcija



Vektorsko predstavljanje teksta

Korišćene tehnike za predstavljanje teksta:

- **Vreće reči (BoW)** – diskretna reprezentacija zasnovana na prisustvu reči (bez redosleda i semantike)
- **Frekvencija termina – Inverzna frekvencija dokumenata (Tf-Idf)** – reprezentacija koja umanjuje uticaj čestih, a ističe informativne termine u dokumentu
- **BERT ugnježdeni vektori reči (BERT-Embd)** – reprezentacija koja enkodiraja semantiku i sintaksu reči u zavisnosti od konteksta



Klasifikacija teksta



Klasifikacija je problem mašinskog učenja (ML) čiji je cilj pronalaženje funkcije koja ulazni skup atributa preslikava u izlazne klase:

$$f_P(T_k) = \phi(T_k) * P, k = 1, 2, \dots, m$$

- Vrste – binarna, višeklasna, višeznačna
- Metrike – tačnost, preciznost, odziv, F1 mera

Klasifikacioni algoritmi:

1. Tradicionalni algoritmi – ERT (ansambl metoda), SGD optimizovana linearna metoda (SVM) ← opsežno pretraživanje
2. Algoritmi dubokog učenja – dvosmerne mreže sa dugom kratkoročnom memorijom (BiLSTM)



Atributi moralnosti i emocionalnosti u klasifikaciji teksta

**Atributi
emocionalnog
aspekta**



**Moralna
vrednost**

**Atributi
moralnog
aspekta**



**Emocionalni
afekt**

**Atributi
drugih
aspekata**



**Drugi
kategorizacioni
kontekst**

Klasifikacioni ML algoritam

Pridruženi (META) atributi klasifikacije

Grupa	Oznaka	Opis	Zadatak	Vrsta	Jezik
Leksički	LexAtr				
Sinktatički	SntAtr	Analiza leksičke složenosti i strukture jezika poruke	NZ	DZ	DZ
Indikacije	IndAtr	Mere pojavljivanje specijalnih indikatora u sadržaju	Z	Z	Z
Interpunkcije	PncAtr	Mere upotrebu interpunkcijskih znakova	NZ	NZ	NZ
Imenovanih entiteta	NERAtr	Omogućavaju identifikaciju i prebrojavanje relevantnih imenovanih entiteta unutar sadržaja poruka	Z	NZ	Z
Konverzacioni	ConAtr	Mere karakteristike veza između poruka u konverzaciji	Z	Z	DZ
Izražajnosti	ExpAtr	Fokusiraju se na ocenu čitljivosti i subjektivnosti sadržaja	NZ	NZ	Z
Emocionalnosti	EmoAtr	Pružaju uvid u emocionalni afekt u sadržaju merenjem broja ili intenziteta prepoznatih afektivnih reči	NZ	NZ	Z
Moralnosti	MorAtr	Mere prisustvo moralnih signala u sadržaju	NZ	NZ	Z

Pronalaženje značajnih atributa

Korišćene tehnike za pronalaženje značajnih atributa:

- **F-statistika** – pristup jedne promenljive
- **Permutacija vrednosti i isključivanje atributa** – pristup više promenljivih
- Kombinovanje dobijenih skupova iz različitih pristupa korišćenjem operacije preseka i statističke mere značajnosti ($p < 0.005$)

$$MSB = \frac{\sum_{i=1}^k n_i (\bar{X}_i - \bar{X})^2}{k - 1}$$

$$MSW = \frac{\sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2}{N - k}$$

$$F_s = \frac{MSB}{MSW}$$



PL		TD		IG	
Atribut	F_s	Atribut	F_s	Atribut	F_s
recipient_dom_coherency	510.08	question_marks_ratio	468.88	avg_sentence_length	240.39
free_domains_ratio	459.74	sentences	387.91	ASPS	219.51
joy	369.24	trust	338.62	fear	213.54
difficult_words_ratio	255.37	adv_ratio	322.64	fairness_sent	207.13
ASPS	219.92	spaces_ratio	275.13	LWM	206.49
LWM	203.53	noun_ratio	247.13	anger	188.59
ARI	192.83	content_lex_count	245.26	authority_p	173.77
business_indicator	178.55	syllable_count	232.67	names_lex_ratio	169.14
exclamation_marks_ratio	172.30	content_lex_length	202.90	anticipation	160.90
avg_sentence_length	144.63	noun_phrases_ratio	187.58	care_p	150.28
avg_word_length	134.04	authority_sent	156.30	disgust	148.90
subject_lex_length	127.22	care_sent	150.55	polarity	142.73

```
PL: značajni atributi = [
    "recipients_count",
    "subject_lex_length",
    "recipients_domains_coherency",
    "positive",
    "joy",
    "loyalty_p",
    "moral_nonmoral_ratio",
    "polarity",
    "trust",
    "LWM",
    "avg_word_length",
    "free_domains_ratio",
    "sanctity_p",
    "business_indicator",
    "surprise",
    "fairness_p"
]
```

Dijagram toka predložene metode dubokog učenja

Ulazna sekvenca

(BERT ugnježdeni vektor)


BiLSTM - grana

(više slojeva)

BiLSTM - poruka

(više slojeva)

Mreža sa propagacijom unapred (FFN)



META atributi

(opciono)

Mehanizam pažnje

(opciono)

Izlazna kategorija

(sigmoid/softmax
aktivaciona funkcija)

Skupovi podataka korišćeni u istraživanju

	 Enron¹	 Redit	 Twiter
Tip	Poruke elektronske pošte Enron korporacije	Objave i komentari sa Redit platforme	Objave i komentari sa Twiter platforme
Stil	Formalni, poslovni	Neformalni	Neformalni
Jezik	Engleski	Engleski i srpski	Engleski i srpski
Zadatak/ Vrsta/ Obeležja	PL (binarna, P/L)	TD, IG (više-klasna, S/D/Q/C; T/F/UNF) ² ; Emo, Mor (više-značajna, Emo/Mor kategorije)	TD, IG (više-klasna, S/D/Q/C; T/F/UNF) ² ; Emo, Mor (više-značajna, Emo/Mor kategorije)

¹ Obeleženi skup podataka za PL zadatak obezbeđen uz podršku istraživača sa Univerziteta Kolumbija

² Obeleženi skupovi podataka za TD/IG zadatke predstavljeni su u okviru [SemVal2019](#) takmičenja

Rezultati klasifikacije – **Msg** eksperiment

Eksperimenti:

1. **Msg** – pojedinačna poruka
2. **Brch** – konverzacioni niz
3. **Ext** – prošireni tekstualni sadržaj poruke

Zadatak:

1. **PL** – SGD-SVM+Tf-Idf+META pokazao najbolje performanse
2. **TD** – mehanizam pažnje, uključivanje META atributa, EmoAtr+MorAtr poboljšavaju performanse osnovnog modela ~1.6% Acc

 Zadatak PL			 Zadatak TD		
Metoda	Acc	F1	Metoda	Acc	F1
BiLSTM/Embd	0.914	0.690	BiLSTM/Embd	0.719	0.443
BiLSTM+Att/Embd	0.921	0.696	BiLSTM+Att/Embd	0.749	0.491
SGD-SVM/Tf-Idf	0.925	0.710	BiLSTM/Embd+META	0.747	0.470
BiLSTM/Embd+META	0.915	0.678	BiLSTM+Att/Embd+META	0.753	0.519
BiLSTM+Att/Embd+META	0.923	0.668	BiLSTM+Att/Embd+EmoAtr	0.751	0.509
SGD-SVM/Tf-Idf+META	0.926	0.709	BiLSTM+Att/Embd+MorAtr	0.749	0.494
			BiLSTM+Att/Embd+EmoAtr+MorAtr	0.735	0.524

Rezultati klasifikacije – Brch eksperiment

 Zadatak PL			 Zadatak IG			 Zadatak TD		
Metoda	Acc	F1	Metoda	Acc	F1	Metoda	Acc	F1
BiLSTM/ Embd	0.938	0.753	BiLSTM/ Embd	0.490	0.405	BiLSTM/ Embd	0.760	0.460
SGD-SVM/ Tf-Idf	0.957	0.841	BiLSTM+Att/ Embd	0.505	0.417	BiLSTM+Att/ Embd	0.727	0.510
BiLSTM/ Embd+META	0.941	0.778	BiLSTM/ Embd+META	0.518	0.430	BiLSTM/ Embd+META	0.765	0.485
SGD-SVM/ Tf-Idf+META	0.957	0.839	BiLSTM+Att/ Embd+META	0.540	0.455	BiLSTM+Att/ Embd+META	0.770	0.535
			BiLSTM+Att/ Embd+EmoAtr	0.525	0.438	BiLSTM+Att/ Embd+EmoAtr	0.765	0.525
			BiLSTM+Att/ Embd+MorAtr	0.520	0.428	BiLSTM+Att/ Embd+MorAtr	0.762	0.510
			BiLSTM+Att/ Embd+EmoAtr+ MorAtr	0.532	0.445	BiLSTM+Att/ Embd+EmoAtr+ MorAtr	0.760	0.545

Rezultati klasifikacije – **Ext** eksperiment


Zadaci:

1. **PL** – dodavanje sadržaju poruke domene adresa primaoca (primeri: *enron.com*, *hotmail.com*, *yahoo.com*)
2. **IG** – dodavanje sadržaju poruke identifikovan tip delovanja (upit - Q, komentar - C, podrška - S, opovrgavanje – D)

Ext pristupom se povećava tačnost klasifikacije za:

1. PL – za ~2.1%
2. IG – za ~2.8%

 Zadatak PL			 Zadatak IG		
Metoda	Acc	F1	Metoda	Acc	F1
MSG/BiLSTM/ Embd+META	0.925	0.708	BiLSTM/ Embd	0.515	0.432
MSG/SGD-SVM/ Tf-Idf+META	0.929	0.730	BiLSTM+Att/ Embd	0.528	0.448
BRCH/BiLSTM/ Embd+META	0.940	0.765	BiLSTM/ Embd+META	0.550	0.460
BRCH/SGD-SVM/ Tf-Idf+META	0.958	0.845	BiLSTM+Att/ Embd+META	0.570	0.485
			BiLSTM+Att/ Embd+EmoAtr	0.555	0.470
			BiLSTM+Att/ Embd+MorAtr	0.552	0.465
			BiLSTM+Att/ Embd+EmoAtr+ MorAtr	0.560	0.475




Jezički resursi za srpski jezik

Emocije i moral

Izgradnja resursa – glavni koraci

Prikupljanje podataka

društvene mreže Twitter i Redit




Harmonizacija korpusa

slaganje anotatora, konsenzus obeležja



Provera modela

super-evaluacija obeležja



Obeležavanje

višeznačno u Emo/Mor kategorije




Izgradnja ML modela

doobučavanje (BERT/ LLaMa)



Izgradnja leksikona

automatska/ručna



Prikupljanje, izbor, obeležavanje i harmonizacija

- Društvene mreže Twitter (X) i Redit – poruke pisane na srpskom jeziku u vremenskom periodu 2020-2022.
- Zadržati strukturu konverzacije (objave/komentari)
- Predobeležavanje pomoću velikih jezičkih modela – **Twitter-XLM-RoBERTa-Es, Falcon-7b-Instruct**
- **Social-Emo.SR (~32k) → Social-Mor.SR (~13.6k)**
 - Podkorporusi **Twitter-Emo.SR (~16.7k)** i **Reddit-Emo.SR (~17.9k)**
 - Korpus za moral - izbor zasnovan na pretraživanju po ključnim rečima:
“poštenje”, “pravda”, “saosećanje”, “zlo”, “dobro”, “odgovornost”, “dužnost”, “istina”, “pravednost”, “korupcija”, “politika”, “sloboda”, “protest”, “nepravda”, “zdravstvo”, “obrazovanje”, “narod”, “lider”, “institucija”
 - Podkorporusi **Twitter-Mor.SR (~6.1k)** i **Reddit-Mor.SR (~7.5k)**
- Definisane višeznačne šeme obeležavanja zasnovane na Plutčikovoj i MFT kategorizaciji
- Svaku poruku je proveravalo 2 (različita) anotatora
- Uspostavljeno preslikavanje između prepoznatih ključnih reči i kategorija da bi se obezbedila konzistentnost obeležavanja
- Slaganje anotatora – Kohenov kapla koeficijent (k) **~0.3** (Emo, 9) i **~0.2** (Mor, 11)
- Harmonizacija korpusa:

$$\text{Gold label} = \sum_m \text{mode}_m(A_l), \text{ mode}_m(A_l | l \in L, l \neq m) < \text{mode}_t(A), m \leq t \leq n \leq L$$


Primeri obeleženih poruka iz Social-Mor.SR korpusa

- Jedinstveni identifikator poruke
- Anonimizovan sadžaj poruka
- Obeležja pojedinačnih anotatora
- Izračunata harmonizovana obeležja (*eng. gold*)
- Standardan JSON format obeleženog korpusa

```
"Messages": [
  {
    "id": 1555574367601299456,
    "annotations": [
      {
        "annotator": "annotator-1",
        "annotation": "care,loyalty"
      },
      {
        "annotator": "annotator-2",
        "annotation": "harm"
      },
      {
        "annotator": "gold",
        "annotation": "care,harm,loyalty"
      }
    ]
  },
  {
    "id": 1555883103251488769,
    "annotations": [
      {
        "annotator": "annotator-1",
        "annotation": "betrayal,cheating,harm"
      },
      {
        "annotator": "annotator-2",
        "annotation": "betrayal,cheating"
      },
      {
        "annotator": "gold",
        "annotation": "betrayal,cheating"
      }
    ]
  },
  ...
]
```



Izgradnja ML modela za prepoznavanje emocionalnog i moralnog signala u porukama

- **Zadatak** – višeznačna klasifikacija u Emo/Mor kategorije:
 - Emocionalni afekt – 9 kategorija
anger, anticipation, disgust, fear, joy, sadness, surprise, trust + neutral(sr. *ljutnja, iščekivanje, gađenje, strah, radost, tuga, iznenađenje, poverenje + neutralna*)
 - Moralna vrednost ili sentiment – 6/11 kategorija
care/harm, authority/subversion, fairness/cheating, loyalty/betrayal, purity/degradation + non-moral
(sr. *briga/povreda, autoritet/subverzija, pravednost/varanje, lojalnost/izdaja, svetost/degradacija + ne-moralna*)
- **Osnovni modeli** – različiti modeli transformer arhitekture koji podržavaju srpski jezik (enkoder, dekodeer)
 - XLM-R (osnovni/veliki), Twitter-XLM-R (osnovni/veliki)
 - Jerteh-81/355, BERTić,
 - LLaMa-3.2-3B-Instruct
- **Doobučavanje** – na poslednjem sloju osnovnog modela
- **Eksperimenti:**
 - Maskiranje specijalnih tokena (@user, #hash, <http>)
 - Isključivanje retkih obeležja (< 4 dodeljenih kategorija)
 - Isključivanje *neutral/non-moral* kategorije (5/10 klasifikacionih kategorija)



Rezultati doobučavanja modela

- **Osnovni modeli** – različiti modeli transformer arhitekture koji podržavaju srpski jezik
 - **XLM-R (~270M/~550M)** – višezječni, Twitter-XLM-R (~270M/~550M) – doobučen za Tviter žargon
 - **Jerteh-81/355, BERTić (~110M)** – obučeni na SBH jezicima,
 - **LLaMa-3.2-3B-Instruct** – optimizovan za generativne zadatke, doobučen korišćenjem specijalno dizajniranih instrukcija za klasifikaciju teksta
- Modeli sa većim brojem parametara pokazali bolje performanse
- Prethodno obučavani modeli za govorni stil (žargon, Tviter) pokazali bolje performanse
- LLaMa-3.2-3B model zahteva dodatno doobučavanje za srpski jezik




Izgradnja alata za merenje intenziteta sentimenta – SRPOL

- Formiranje **SentiWords.SR** leksikona ~15k lema srpskog jezika sa pridruženim vrednostima polariteta u rang [-1,+1]
- Po uzoru na analogni leksikon na engleskom jeziku:

Gatti L., Guerini M., and Turchi M. (2015): SentiWords: Deriving a high precision and high coverage lexicon for sentiment analysis. IEEE Transactions on Affective Computing, 7(4), 409-421

- Automatsko prevođenje: korektni prevodi ~48.3%, delimično korektni ~18%, nekorektni ~33.7% → ručna provera
- Pokretači intenziteta sentimenta – negacije, prilozi, emotikoni, interpunkcijski znakovi → skupovi pravila
- Segmentacija teksta i agregacija vrednosti



$$P_s = \frac{\sum_i^k P_w^i}{k}$$

$$P_{text} = \frac{\sum_i^S w_i * P_s^i}{\sum_i^S w_i}, w_i = \sum_m |sign(P_s^i) = sign(P_s^m)|$$

Algoritam 8.1: Kreiranje SentiWords.SR leksikona

FindPolarity

inputs: SentiWords; GT

output: SentiWords.SR

foreach $lema_{En}, PoS \in SentiWords$ **do**

$score \leftarrow score(lema_{En}, PoS);$

$lema_{Sr}, PoS \leftarrow clean(GT(lema_{En}, PoS));$

$lema_{Sr}, PoS \leftarrow score(lema_{En}, PoS);$

$SentiWords.SR \leftarrow evaluate(lema_{Sr}, PoS, score);$

foreach $lema_{Sr}, PoS \in SentiWords.SR$ **do**

$score \leftarrow mean(lema_{Sr}, PoS, score);$


$std \leftarrow std(lema_{Sr}, PoS, score);$

$count \leftarrow count(lema_{Sr}, PoS);$

return SentiWords.SR;

Izgradnja leksikona emocionalnih lema – EmoLex.SR

- EmoLex.EN → prevođenje, prilagođavanje, proširivanje → EmoLex.SR
- Prevođenje: Gugl Prevodilac, Čet-GPT
- Prilagođavanje obeležja: EmoLex.EN + Čet-GPT + WNA.SR → EmoLex.SR
- Proširivanje: skup sinonima – SWN, Čet-GPT
- Provera leksikona nad tekstualnim kolekcijama: LLM.SR, XED.SR



- Provera Čet-GPT izlaza:
 1. Prevođenje (tačnost lema, vrsta reči, više-rečnih izraza, semantičko pomeranje)
 2. Obeležavanje,
 3. Generisanje sinonima,
 4. Generisanje paralelnog korpusa
- Leksikon ~9.8k lema srpskog jezika

```
„EmoLex.SR“: [
{
  "lemma": potlačiti,
  "pos": VERB,
  "weights": {
    "anger": 0.25,
    "anticipation": 0.0,
    "disgust": 0.25,
    "fear": 0.25,
    "joy": 0.0,
    "surprise": 0.0,
    "sadness": 0.25,
    "trust": 0.0,
    "neutral": 0.0
  },
  "label": anger|disgust|fear|sadness
},
...
]
```

Šošić, M., Graovac, J., Stanković R. (2025). Building an Emotion Lexicon for Serbian Using Curated Language Resources, Language Resources and Evaluation, Springer, Forthcoming

Provera leksikona emocionalnih lema – EmoLex.SR

- Provera izvršena nad LLM-Emo.SR i XED-Emo.SR skupovima paralelnih rečenica
- Leksikoni EmoLex.SR-v(1/2) nadmašuju leksikon dobijen automatskim prevođenjem (osnova)
- Automatskim prevođenjem se smanjuje tačnost poređenjem nad skupovima prevodnih ekvivalenata
- Prilagođavanje jezičkim i kulturološkim karakteristikama postiže se optimalna tačnost

	NRC.EmoInt.tr (osnova)			EmoLex.SR-v1			EmoLex.SR-v2		
LLM-Emo.SR	F ₁	Prec	Rec	F ₁	Prec	Rec	F ₁	Prec	Rec
<i>anger</i>	0.852	0.958	0.767	0.784	0.833	0.741	0.809	0.792	0.826
<i>anticipation</i>	0.740	0.626	0.905	0.783	0.714	0.867	0.723	0.615	0.875
<i>disgust</i>	0.732	0.577	1.000	0.800	0.692	0.947	0.808	0.731	0.905
<i>fear</i>	0.831	0.822	0.841	0.819	0.756	0.895	0.874	0.844	0.905
<i>joy</i>	0.728	0.639	0.848	0.720	0.651	0.806	0.745	0.669	0.841
<i>sadness</i>	0.700	0.636	0.778	0.876	0.836	0.920	0.830	0.800	0.863
<i>surprise</i>	0.500	0.346	0.900	0.638	0.577	0.714	0.644	0.538	0.800
<i>trust</i>	0.442	0.358	0.576	0.586	0.641	0.539	0.661	0.679	0.643
Macro Avg	0.691	0.620	0.827	0.751	0.792	0.804	0.762	0.708	0.832
XED-Emo.SR	F ₁	Prec	Rec	F ₁	Prec	Rec	F ₁	Prec	Rec
<i>anger</i>	0.104	0.060	0.392	0.131	0.078	0.416	0.114	0.065	0.453
<i>anticipation</i>	0.151	0.094	0.383	0.207	0.138	0.413	0.281	0.222	0.381
<i>disgust</i>	0.112	0.064	0.432	0.123	0.078	0.285	0.159	0.114	0.260
<i>fear</i>	0.187	0.133	0.318	0.191	0.138	0.313	0.181	0.126	0.317
<i>joy</i>	0.282	0.212	0.422	0.369	0.324	0.431	0.418	0.449	0.391
<i>sadness</i>	0.196	0.135	0.357	0.232	0.170	0.365	0.255	0.209	0.327
<i>surprise</i>	0.052	0.029	0.259	0.060	0.0334	0.293	0.148	0.099	0.295
<i>trust</i>	0.167	0.129	0.230	0.266	0.301	0.238	0.295	0.370	0.245
Macro Avg	0.156	0.107	0.349	0.197	0.157	0.344	0.231	0.207	0.334


Leksikon	LexCvg	EMR	Acc	F ₁	Prec	Rec	HS	HL
NRC.EmoInt	0.950	0.534	0.912	0.694	0.618	0.802	0.649	0.087
NRC.EmoInt.tr	0.928	0.535	0.917	0.691	0.620	0.827	0.652	0.083
EmoLex.SR-v1	0.975	0.560	0.922	0.751	0.713	0.804	0.706	0.077
EmoLex.SR-v2	0.995	0.585	0.927	0.762	0.708	0.832	0.723	0.072

Izgradnja leksikona moralnih lema – MFD.SR


- Obeleženi korpus → izdvajanje karakterističnih reči → leksikon
- Čišćenje teksta i obrada (PoS obeležavanje, lematizacija, NE uklanjanje)
- SRPOL (SentiWords.SR) za određivanje sentimenta teksta-reči
- Kosinusna sličnost između reči za pronalaženje derivacija reči
- c-Tf-Idf algoritam predstavljen formulom:

$$c\text{-TF-IDF}(t, c) = \text{TF}(t, c) \times \log \left(\frac{N}{|C_t|} \right)$$

- MFD.SR ~4.3k lema srpskog jezika



```
"MFD.SR": [
{
  "lemma": diskriminacija,
  "PoS": NOUN,
  "weights":
  {
    "authority": 0.18,
    "care": 0.16,
    "fairness": 0.25,
    "loyalty": 0.14,
    "purity": 0.27
  },
  "sentiment": -0.64,
  "moral_foundation": purity,
  "moral_sentiment": purity.vice,
  "moral_category": degradation
},
]
```




Anketa o razumevanju moralnih vrednosti

● **29.7%**

Odraslih


Volonteri sa društvenih mreža



● **70.3%**

Studenata


Volonteri sa Beogradskog Univerziteta



- Anonimna i volontarna
- 370 ispitanika

- 3 grupe pitanja:

1. Socio-demografska – 9
2. Razumevanje moralnih vrednosti – 10 → provera leksikona
3. MFQ – 32 → korelisanje sa identifikovanim moralnim lemapa



Provera leksikona moralnih lema – MFD.SR

- Deskriptivni opisi o razumevanju moralnih vrednosti – 10 pitanja

authority: $F_s=34.4, p \leq 0.05$

care: $F_s=138.9, p \leq 0.05$

fairness: $F_s=40.9, p \leq 0.05$

loyalty: $F_s=55.5, p \leq 0.05$

purity: $F_s=39.4, p \leq 0.05$

- Korelacija identifikovanih moralnih lema sa vrednostima iz upitnika


authority: $r=0.07, p=0.20$

care: $r=0.13, p=0.01$

fairness: $r=0.10, p=0.07$

loyalty: $r=0.11, p=0.03$

purity: $r=0.04, p=0.47$



Razvijeni jezički resursi za emocije i moral

Aspekt 	Emocije		Moral	
	Naziv	Statistika	Naziv	Statistika
Resurs  Korpus	Social-Emo.SR	~34.6k obeležених poruka	Social-Mor.SR	~13.6k obeležених poruka
Leksikon	EmoLex.SR	~9.8k obeležених srpskih lema	MFD.SR	~4.3k obeležених srpskih lema
Model	BERT-Emo.SR LLaMa-Emo.SR	~8 doobučених modela (BERT/LLaMa)	BERT-Mor.SR LLaMa-Mor.SR	~8 doobučених modela (BERT/LLaMa)

Međusobna zavisnost između emocionalnih i moralnih atributa

- Obeležen korpus na ove aspekte (Twitter-Mor.SR)
- Raspodela emocionalnih po moralnim kategorijama
- Normalizovana učestalost pojavljivanja


degradation, cheating, betrayal, subversion, harm → anger, sadness

purity, loyalty, care → joy

care, loyalty, fairness → trust

care → sadness, anticipation

- Potvrđena ispravnost uspostavljenih šema obeležavanja i harmonizacije obeležja nad izgađenim korpusima
- Potrebna dodatna provera obeležja za potvrđivanje uočenih korelacija između kategorija



Diskusija

Hipoteza 1

Uključivanje moralnih i emocionalnih aspekata jezika značajno doprinosi tačnosti modela klasifikacije konverzionih tekstova, što ukazuje na njihov značaj u interpretaciji i razumevanju konverzionih tekstova.

Uključivanje Emo i Mor atributa pokazali su poboljšanje performansi klasifikacije na različitim zadacima – IG/TD ~+4.2/3.8% F1

Hipoteza 2

Kvantitativnom analizom atributa moguće je utvrditi korelaciju između iskazanih moralnih stavova i emocionalnih reakcija u konverzionim porukama.

Kvantitativna analiza nad obeleženim tekstovima u oba aspekta potvrdila je određeni stepen korelacije u zajedničkom pojavljivanju Emo i Mor kategorija.

Hipoteza 3

Razvijeni semantički leksikoni moralnih i emocionalnih afekata reči za srpski jezik mogu doprineti prepoznavanju ovih aspekata u tekstu.

Leksikoni EmoLex.SR i MFD.SR potvrdili su svoju uspešnost u prepoznavanju ovih aspekata jezika na tekstovima iz različitih domena i govornih stilova.

Hipoteza 4

Moguće je razviti klasifikacione modele prihvatljive tačnosti koji na osnovu karakteristika tekstualnih sadržaja iz razvijenih obeleženih konverzionih korpusa na srpskom jeziku, mogu da prepoznaju moralne i emocionalne aspekte jezika.

Razvijeni klasifikacioni modeli su u rang sa do sada objavljenim naprednim modelima na istim zadacima: ~53% F1 (Emo), ~46/38% F1 (Mor).

Zaključak i dalji rad

- Potvrđena uspešnost predložene (hibridne) metodologije za klasifikaciju konverzacionih tekstova (PL, IG, TD)
- Utvrđen značaj emocionalnih i moralnih atributa na ovim zadacima
- Razvijeni novi resursi za srpski jezik koji pokrivaju ove aspekte jezika (leksikon, korpus, model)
- Unapređeni postojeći resursi uključivanjem emocionalnog aspekta (WNA.SR → SWN)

Dalji rad:

- Dodatna provera razvijenih resursa i njihovo objavljivanje:
 1. Obeleženih korpusa emocionalnog afekta i moralnog sentimenta,
 2. Lekiskona moralnih lema,
 3. Naprednih klasifikacionih ML modela za prepoznavanje emocionalnog afekta i moralnih vrednosti/sentimenta u tekstovima na srpskom jeziku
 4. Analiza pomeranja emocionalnih kategorija pod uticajem neposredne negacije (opseg delovanja, pokretači emocionalnih promena, matrica verovatnoća)
 5. Provera i unapređenje razvijenog SRPOL alata
- Predlaganje algoritma za merenje čitljivosti tekstova na srpskom jeziku
- Unapređenje postojećih algoritama za podelu reči na slogove

```
</SYNSET>
<SYNSET>
  <ID>ENG30-01797051-v</ID>
  <POS>v</POS>
  <SYNONYM>
    <LITERAL>oplakati<SENSE>1</SENSE>
    <LNOTE>V123+Perf+Tr+Iref</LNOTE></LITERAL>
    <LITERAL>tugovati<SENSE>1b</SENSE>
    <LNOTE>V518+Imperf+It+Iref</LNOTE></LITERAL>
    <LITERAL>jadikovati<SENSE>1</SENSE>
    <LNOTE>V518+Imperf+It+Iref</LNOTE></LITERAL>
    <LITERAL>ožaliti<SENSE>1</SENSE>
    <LNOTE>V153+Perf+Tr+Iref</LNOTE></LITERAL>
  </SYNONYM>
  <DEF>Osećati tugu.</DEF> ...
  <SUMO>IntentionalPsychologicalProcess<TYPE>+</TYPE></SUMO>
  <SENTIMENT>
    <POSITIVE>0.00000</POSITIVE>
    <NEGATIVE>0.75000</NEGATIVE>
  </SENTIMENT>
  <DOMAIN>psychology</DOMAIN>
  <AFFECT>regret-sorrow</AFFECT>
  <EMOCAT>sadness</EMOCAT>
</SYNSET>
```

Lista Relevantnih Publikacija – Konverzacija + Klasifikacija

Kochkina, E., Liakata, M., Augenstein, I. (2017). Turing at SemEval-2017 Task 8: Sequential Approach to Rumour Stance Classification with Branch-LSTM, Proceedings of the 11th International Workshop on Semantic Evaluation (SemEval-2017), 475-480

01

Alkhereyf, S., Rambow, O. (2017). Work Hard, Play Hard: Email Classification on the Avocado and Enron Corpora, Proceedings of TextGraphs-11: the Workshop on Graph-based Methods for Natural Language Processing, 57-65

02

Alkhereyf, S., Rambow, O. (2020). Email Classification Incorporating Social Networks and Thread Structure, Proceedings of The 12th Language Resources and Evaluation Conference, 1336-1345

03

Šošić, M., Graovac, J. (2022). Effective Methods for Email Classification: Is it a Business or Personal Email?, Computer Science and Information Systems, 19:1155-1175

04

Lista Relevantnih Publikacija – Emocije

Plutchik R. (2001). The Nature of Emotions: Human emotions have deep evolutionary roots, a fact that may explain their complexity and provide tools for clinical practice, *American scientist*, 89:344-350

01

Mohammad, S., Turney, P. (2013). Crowdsourcing a word-emotion association lexicon, *Computational intelligence*, 29:436-465

02

Ohman, E., Pamies, M., Kajava, K., Tiedemann, J. (2020). XED: A Multilingual Dataset for Sentiment Analysis and Emotion Detection, *Proceedings of the 28th International Conference on Computational Linguistics*, 6542-6552

03

Šošić, M., Graovac, J., Stanković R. (2025). Building an Emotion Lexicon for Serbian Using Curated Language Resources, *Language Resources and Evaluation*, Springer, Forthcoming

04

Lista Relevantnih Publikacija – Moral

Graham, J. a. (2009). Liberals and conservatives rely on different sets of moral foundations. Journal of personality and social psychology, 96, 1029

05

Hoover, J. a.-W. (2020). Moral foundations twitter corpus: A collection of 35k tweets annotated for moral sentiment. Social Psychological and Personality Science, 11(8), 1057-1071

06

Hopp, F. at all. (2021). The extended Moral Foundations Dictionary (eMFD): Development and applications of a crowd-sourced approach to extracting moral intuitions from text, Behavior Research Methods, 53: 232-246

07

Bulla, L. a. (2022). Detection of morality in tweets based on the moral foundation theory, International Conference on Machine Learning, Optimization and Data Science, 1-13

08

Lista Relevantnih Publikacija – Srpski jezik

Krstev, C., Pavlović-Lažetić, G., Obradović, I., Vitas, D. (2003). Corpora issues in validation of Serbian WordNet, International Conference on Text, Speech and Dialogue, Springer, 132-137

09

Ljubešić N., Erjavec T., Fišer D. (2016), Corpus-based diacritic restoration for south slavic languages. In Proceedings of the Tenth International Conference on Language Resources and Evaluation (LREC'16), 3612-3616

10


Stanković, R., Šandrih B., Krstev C., Utvić M., and Škorić M. (2020). Machine learning and deep neural network-based lemmatization and morphosyntactic tagging for Serbian, In Proceedings of The 12th Language Resources and Evaluation Conference, 3954-3962

11

Šošić, M. (2022). SRPOL – A Lexicon Based Framework for Sentiment Strength of Serbian Texts. Review of the NCD, 41:58-73

12

Hvala na pažnji!



pd202030@alas.matf.bg.ac.rs
milena.sosic@gmail.com
+381 64 30 55 705



Jedan deo ovog istraživanja uspešno je sproveden uz podršku
Fonda za Nauku Republike Srbije, u okviru projekta
#7276 Text Embeddings – Serbian Language Applications – TESLA



Фонд за науку
Републике Србије



Тесла