


**mr Milena Šošić
prof. dr Ranka Stanković
prof. dr Jelena Graovac**



Social-EMO.SR:

EMOCIONALNA VIŠEZNAČNA KATEGORIZACIJA

KONVERZACIONIH PORUKA

SA DRUŠTVENIH MREŽA X I REDDIT



Sadržaj

Uvod

3

Prikupljanje i označavanje

4

Provera oznaka

5

Izgradnja AI modela

6

Zaključak


8

**3**

Uvod

- **Cilj: Izgradnja emocionalnog korpusa konverzacionih poruka na srpskom jeziku**
- **Konverzacioni nizovi poruka:**
poruka → grana → konverzacija
- **Izvor podataka: društvene mreže X i Reddit**
- **Višeznačno označavanje u 8 + 1 kategorija prema Plutčikovom modelu**

[anger, anticipation, disgust, fear, joy, sadness, surprise, trust] + neutral

**1**

**Prikupljanje
podataka**

2

**Višeznačno
predoznačavanje
i izbor poruka**

3

**Provera
automatski
dodeljenih
oznaka**

4

**Provera
konzistentnosti i
pravljenje
harmonizovanih
oznaka**

5

**Izgradnja AI
modela za
prepoznavanje
emocionalnog
afekta**



4

Prikupljanje, označavanje, izbor

- **X/Reddit API + pajton biblioteke – period 2020-2022, poruka na **SR** jeziku**
- **Predoznačavanje – napredne AI + NLP tehnike:**
 - **EMO-XLM-RoBERTa** + transferno učenje → prenos znanja na srpski jezik (2 oznake)
 - **NRC.EmoLex.SR** – emocionalni leksikon izgrađen za srpski jezik (1 oznaka)
- **Pravila odabira:**
 - Bar jedna **EMO** oznaka
 - Bar 3 validne leme u tekstualnoj sekvenci poruke
 - Očuvanje konverzacione strukture

	Korpus	Objava	Komentara	Ukupno
Prikupljeno	X	6,9k	109,3k	116,3k
	Reddit	9,1k	131,4k	140,6k
Izabrano	X	5,9k	10,8k	16,7k
	Reddit	5,3k	12,6k	17,9k
	Social	11,2k	23,4k	34,6k

**5**

Provera automatskih oznaka

- Izgradnja anotacione šeme i pravila označavanja
- Ukupno 6 anotatora, po dva paralelno za svaku poruku iz korpusa

Poruka	oznaka1	oznaka2	oznaka3	Oznaka anotatora	Jezik
Nasukani otpad na nikad većim obalama reke, peščani sprudovi gde ih dugo nije bilo. Ovo je slika Dunava tokom jednog od najtoplijih leta u skorijoj prošlosti	sadness	sadness, surprise	anger, disgust, sadness, surprise	1/2/3/A	SR/HR/EN/ drugi

- Prosečan Cohen's Kappa koeficijent ~0.3
- Harmonizovana oznaka:

$$A = \sum_{n,L} \text{Annotator_labels}, |L|=9$$

$$\text{Gold_label} = \sum_m \text{mode}_m(A_l), \text{mode}_m(A_l) | l \in L, l \neq \text{mode}_t(A), m \leq t \leq n \leq L$$



Izgradnja modela

- **Razvoj modela za višeznačnu klasifikaciju korišćenjem **BERT** arhitektura:**
 - **XLM-RoBERTa** (osnovni/veliki)
 - **Twitter-XLM-RoBERTa** (osnovni/veliki)
 - **Jerteh-81/Jerteh-355**
 - **BERTić**
- **Eksperimenti:**
 - Maskiranje tokena: @user, #hash, <http>
 - Isključivanje **neutral** kategorije

	Korpus	F1-Ma	F1-Mi	F1-Wgh	Hamming Score
XLM-RoBERTa	X	0.53	0.62	0.61	0.57
	Reddit	0.47	0.60	0.59	0.54
Twitter-XLM-RoBERTa	X	0.54	0.62	0.62	0.58
	Reddit	0.48	0.61	0.60	0.55
Jerteh-355	X	0.49	0.60	0.59	0.56
	Reddit	0.46	0.60	0.58	0.54
BERTić	X	0.49	0.60	0.59	0.55
	Reddit	0.43	0.59	0.58	0.54

**7**

Primeri označavanja AI modela


- Volim te najviše na svetu. 😍❤️ [joy]
- Verujem u tebe. [joy, trust]
- Očekujem da odgovori na moj poziv. [anticipation, trust]
- Takvo ponašanje me jako ljuti! [anger]
- Kako bih želela da smo opet tamo... [anticipation, sadness]



Zaključak

- **Social-EMO.SR konverzacioni korpus ~34k poruka**
- **Korišćenje u drugim istraživanjima digitalnih komunikacija na srpskom jeziku**
- **Izgrađeni AI modeli prihvatljive tačnosti ~0.54 F1-Ma**
- **Izazovi:**
 - **Preplitanje emocija**
 - **Različito doživljavanje emocionalnih stanja**
 - **Poruke u metaforičnom i ironičnom značenju**
 - **Širi kontekst naspram užeg konteksta**
 - **Pošiljalac → primalac emocionalnog signala**

} liste ključnih reči





9

Plan za dalji rad

Super-evaluacija oznaka

Dodatna provera **tačnosti** oznaka i **statističke** raspodele emocionalnih kategorija

Harmonizacija i statistička analiza korpusa

Harmonizacija oznaka, statističke karakteristike, odnos sa intenzitetom sentimenta, odgovori na emocionalne objave, emocije kroz teme i kontekste

Re-izgradnja AI modela

Ponovna izgradnja modela u cilju poboljšanja tačnosti, primena naprednih tehnika za izgradnju modela (veliki jezički modeli)

Super-evaluacija tačnosti AI modela

Provera tačnosti izgrađenih modela i dalje unapređenje

Objavljivanje

Objavljivanje izgrađenog korpusa i modela za korišćenje od strane drugih istraživača uz primenu etičkih principa i standarda

Hvala na pažnji! 😊

mr Milena Šošić

milena.sosic@gmail.com

Istraživanje sprovedeno uz podršku Fonda za nauku Republike Srbije,
#7276 Text Embeddings - Serbian Language Applications – TESLA,

<https://tesla.rgf.bg.ac.rs/>



Фонд за науку
Републике Србије



Тесла