

ПРИМЕНА КЛАСИФИКАЦИЈЕ НА Н-ГРАМСКУ АНАЛИЗУ ГЕНОМА

Магистарски рад

Студент: Милена Шошић


Ментор: др Ненад С. Митић

Увод


- Значај откривања геномских структура
- Зависност геномских структура од нагомилавање одређених комбинација нуклеотида
- Бактеријски геном као реченица дужине 4 - 6 милиона карактера (нуклеотида) над азбуком од четири слова {A, C, G, T}
- Проналажење подречи дате дужине
 - Учесталост појављивања
 - Очекивано појављивање
 - Стандардна девијација појављивања
 - Z вредност
- Истраживање података - класификација

Утицаји и идеја за решавање проблема

Приказ просечних вредности фреквенција триграма ($n=3$) над регионима генома *Escherichia coli* O157:H7 EDL933 (NC_002655) који су идентификовани као острва (плава линија) и онима који то нису (црвена линија)




Приказ стандардне девијације фреквенције триграма ($n=3$) над регионима генома *Escherichia coli* O157:H7 EDL933 (NC_002655) који су идентификовани као острва (плава линија) и онима који то нису (црвена линија)



Утицаји и идеја за решавање проблема

Илустративни приказ класификованих геномских региона на основу z-вредности учесталости појављивања биграма. На хоризонталној оси су представљени сви биграми, а на вертикалној израчунате z-вредности на примеру генома *Escherichia coli* O157:H7 EDL933. Црвеном бојом означени су региони који су острва, а плавом региони који то нису



Циљ рада

- Прављење методе за предвиђање геномских острва код бактеријских организама
- Примена методе класификације
- Избор одговарајућег алгоритма који најбоље решава проблем
- Предвиђање оквирних позиција “обичних”, али и патогених острва

Н-грам

- Појам Н-грама
- Број различитих Н-грама дужине n , над азбуком A је $|A|^n$ где је $|A|$ број слова у азбуци A .
- Проблеми који се решавају помоћу Н-грама:
 - Проналажење највероватнијег следећег слова у низу за дату секвенцу слова из неке азбуке
 - Прављење модела над текстуалним подацима у алгоритмима машинског учења - претраживач Google
 - Утврђивање сличности међу геномским секвенцама и класификација гена
- Недостатак - кардиналност расте експоненцијалном брзином у односу на дужину Н-грама

Геномска острва

- Дефинишу се као делови ДНК секвенце који су настали у процесу хоризонталног преноса генетског материјала
- Ови региони показују специфичне особине по којима се разликују од остатка секвенце:
 - Показују абнормалности у композицији у односу на остатак секвенце (G+C %, искоришћеност кодона, учесталост H-грама)
 - Често се интегришу у tРНК гене
 - Релативно велике дужине, 10 - 200 Кбп
 - Садрже гене непознатих функција
 - Садрже мобилне гене (интегрони, транспозони, уметнуте секвенце)
 - Нестабилног су понашања

Геномска острва - методе

- Региони који покажу различиту композицију у односу на остатак секвенце имају већу вероватноћу да су настали у поступку хоризонталног преноса гена
- Недостаци овог приступа су :
 - Геном може природно да варира под утицајем високо изражених гена
 - Хоризонтално пренети ДНК током времена може да се прилагоди организму домаћина
 - Хоризонтално пренети ДНК може да води порекло од организма који има геномску секвенцу сличну геномској секвенци домаћина
- Компаративни метод пореди функционалне регионе више геномских секвенци блиских врста да би предвидео постојање геномског острва
- Недостаци овог приступа су:
 - Избор сличних генома води предвиђању само нових острва
 - Избор различитих генома води већој грешци предвиђања
 - Мали број секвенционисаних генома за поређење

Z вредност

- Ова вредност је заносвана на Марковљевом моделу максималног реда и представњена је нормализованом разликом између стварног и очекиваног броја појављивања за дати Н-грам:

$$z(n_1 n_2 \dots n_k) = \frac{N(n_1 n_2 \dots n_k) - E(n_1 n_2 \dots n_k)}{\sigma(n_1 n_2 \dots n_k)}$$

$$E(n_1 n_2 \dots n_k) = \frac{N(n_1 n_2 \dots n_{k-1}) \times N(n_2 n_3 \dots n_k)}{N(n_2 n_3 \dots n_{k-1})}$$

σ^2

$$= E(n_1 n_2 \dots n_k)$$

$$\times \frac{[N(n_2 n_3 \dots n_{k-1}) - N(n_1 n_2 \dots n_{k-1})] \times [N(n_2 n_3 \dots n_{k-1}) - N(n_2 n_3 \dots n_k)]}{N(n_2 n_3 \dots n_{k-1}) \times N(n_2 n_3 \dots n_{k-1})}$$

Метода класификације

- Класификација је метода истраживања података која смешта објекте у одређене класе или категорије
- Циљ ове методе је да што тачније предвиди класу којој неки објекат из скупа података припада
- Ова метода захтева постојање скупа података у коме је сваком објекту придружена одговарајућа класа – скуп подата за учење
- Одређују се атрибути на основу чијих вредности ће се вршити класификација, као и атрибут који приказује припадност класи, а који мора да има дискретну вредност

Матрица тачности

ТП (Тачна Позитивна, енг. *True Positives*) број објеката који припадају класи Позитивна и којима је предвиђена иста класа

ПП (Погрешна Позитивна, енг. *False Positives*) број објеката који припадају класи Негативна, али им је предвиђена припадност класи Позитивна

ПН (Погрешна Негативна, енг. *False Negatives*) број објеката који припадају класи Позитивна, али им је предвиђена припадност класи Негативна

ТН (Тачна Негативна, енг. *True Negatives*) број објеката који припадају класи Негативна и којима је предвиђена иста класа

Предвиђање	Стварна вредност	
Позитивна	Позитивна	Негативна
	ТП	ПН
Негативна	ПП	ТН

Прецизност = $\frac{TP}{TP + PP}$

Одзив или ТП мера = $\frac{TP}{TP + PN}$

Тачност = $\frac{TP + TN}{TP + TN + PP + PN}$

F = 2 * $\frac{\text{Прецизност} * \text{Одзив}}{\text{Прецизност} + \text{Одзив}}$

Коришћени алгоритми

- *Naive Bayes* алгоритам
- *C4.5* алгоритам
- *Ripper* алгоритам


Поређење алгоритама

Поређење квалитета резултата алгоритама класификације NaiveBayes, C4.5 и RIPPER у зависности од дужине Н-грама извршеним над изолатом [Escherichia coli str. K-12 substr. W3110](#). Тамнијом бојом су означене комбинације алгоритама – дужина н-грама које су дале најбоље резултате мере F. Ови резултати су даље филтрирани према величини предвиђеног острва које је имало одлучујућу улогу у коначној одлуци за избор комбинације дужина Н-грама и алгоритама новоизграђене методе по којој би се вршила класификација

Дужина н-грама	Алгоритам/Мера	Naive Bayes	C 4.5	RIPPER
2-грам	Прецизност	44.68%	94.12%	79.31%
	Одзив	68.75%	56.25%	75%
	F-мера	54.16%	70.42%	77.09%
	Величина острва	22 819.15	21 911.76	23 965.52
3-грам	Прецизност	30.76%	83.33%	73.91%
	Одзив	78.125%	75%	65.62%
	F-мера	44.20%	78.94%	69.52%
	Величина острва	24 679.49	29 166.67	27 065.22
4-грам	Прецизност	46.80%	74.07%	90.09%
	Одзив	90.63%	78.13%	37.50%
	F-мера	61.72%	76.04%	52.96%
	Величина острва	86 606.38	40 277.78	38 181.82
5-грам	Прецизност	87.50%	100.00%	100.00%
	Одзив	78.13%	53.13%	6.25%
	F-мера	82.55%	69.39%	11.76%
	Величина острва	137 656.3	78 181.82	23 750


Поређење алгоритама

Поређење добијених
вредности F-мере
алгоритама
класификације
NaiveBayes, C4.5 и
RIPPER у зависности
од дужине n-грама
извршеним над
изолатом Escherichia
coli str. K-12 substr.
W3110.



Поређење алгоритама

Поређење добијених
вредности за
величину
предвиђеног острва
алгоритама
класификације
NaiveBayes, C4.5 и
RIPPER у зависности
од дужине н-грама
извршеним над
изолатом Escherichia
coli str. K-12 substr.
W3110.



Материјал

- У току рада коришћено је више извора база геномских података за набављање неопходног материјала за истраживање, као и за поређење добијених резултата:
 - NCBI Entrez
 - IslandViewer
 - PAI DB
- Први скуп података – *Escherihia* и *Shigella*
- Други скуп података – *Neisseria meningitidis*, *Photorhabdus luminescens*, *Pseudomonas syringae*, *Salmonella enterica*, *Xanthomonas oryzae* и *Yersinia pestis*
- Алати – Weka, Tanagra, Artemis

Метода

- Припрема података за класификацију
- Класификација података у алату WEKA
- Обрада добијених резултата, анализа и предвиђање острва
- Главни принципи:
 - Класификација свих H-грама одређене дужине на основу статистичких карактеристика - учесталост појављивања и z вредност на прозорима сталне дужине 10 Кбп, са померањем прозора од 2.5 Кбп
 - Атрибут који приказује припадност класи има вредности ДА или НЕ у зависности да ли прозор цео припада региону које је означено као геномско острво

Припрема података

Преузимање геномских датотека
из база геномских података


Обрада ових датотека и
прављење одговарајућих
датотека са корисним
информацијама о геномима

Унос датотека са корисним
информацијама у базу података

Прављење скриптова за додатну
реорганизацију података


Прављење текстуалних датотека
за учење и тестирање модела
класификације

Филтер атрибута и конвертовање
докумената у ARFF формат ради
ефикасније примене у алату
WEKA




Класификација

Прављење и тестирање
модела за класификацију
података



Обрада резултата

1. Спајање датотеке резултата класификације и датотеке над којом је примењено тестирање
2. Анализирање спојене датотеке
3. Предвиђање острва



Спојена датотека

Пример спојеног документа Merged-*.csv изолата [Salmonella enterica subsp. enterica serovar Choleraesuis str. SC-B67](#) за дужину Н-грама 2 . Приказана је група свих Н-грама дате дужине у датом прозору и за дато удаљење. Последња колона преставља резултат примене класификације над документом за тестирање овог изолата – редни број инстанце у документу, вредност атрибута по коме се врши класификација (?), предвиђена вредност атрибута класификације (YES, NO) и тачност са којом се предвиђа

Н-грам	Број појављивања	Z-вредност	Острво	Удаљење	Број Прозора	Предвиђање			
AA	1470	1.2042	?	0	35	2177	1:?	1:NO	0.913
AC	1114	1.0044	?	0	35	2178	1:?	1:NO	0.967
AG	1143	2.2673	?	0	35	2179	1:?	1:NO	0.642
AT	1484	2.8552	?	0	35	2180	1:?	1:NO	0.94
CA	1436	2.3564	?	0	35	2181	1:?	2:YES +	0.76
CC	1236	0.1131	?	0	35	2182	1:?	1:NO	0.967
CG	974	-11.7238	?	0	35	2183	1:?	2:YES +	0.731
CT	1143	2.2673	?	0	35	2184	1:?	1:NO	0.642
GA	1235	1.4686	?	0	35	2185	1:?	1:NO	0.688
GC	1202	-9.3279	?	0	35	2186	1:?	2:YES +	0.8
GG	1236	0.1131	?	0	35	2187	1:?	1:NO	0.967
GT	1114	1.0044	?	0	35	2188	1:?	1:NO	0.967
TA	1070	2.2982	?	0	35	2189	1:?	1:NO	0.966
TC	1235	1.4686	?	0	35	2190	1:?	1:NO	0.688
TG	1436	2.3564	?	0	35	2191	1:?	2:YES +	0.76
TT	1470	1.2048	?	0	35	2192	1:?	1:NO	0.913

Датотека са статистичким подацима

Пример Statistics-*.csv датотеке настале анализом спојене датотеке Merged-*.csv на примеру изолата [Escherichia coli O157:H7 str. Sakai](#) (NC_002695). Приказан је регион који је кандидат за острво: низ узастопних прозора код којих је вредност ДА бројача позитивна и већа од унапред утврђене границе, као и проценат Н-грама из ове групе који садрже подниску GC или CG

Удаљење	Број Прозора	Н-грами који показују специфично понашање	Проценат GC и CG нуклеотидних парова	Да Бројач	Да Тачност	Не Бројач	Не Тачност
7500	30		0	0	NaN	64	0.902375
0	31	CGA;CGC;GCG;TCG	100	4	0.5945	60	0.830933
2500	31	ACC;AGA;CCG;CGC;CGG;CTC;GAG;GCG;GGA;GGT;TCC;TCT	33.33333	12	0.572	52	0.830731
5000	31	AAA;ACC;AGA;CAC;CCA;CCG;CGA;CGC;CGG;CTA;GCC;GCG;GGC;GGT;GTG;TAG;TCA;TCG;TCT;TGA;TGG;TTT	36.36364	22	0.584818	42	0.772334
7500	31	AAA;ACC;AGA;CAC;CCA;CCG;CGA;CGC;CGG;CTA;CTC;GAG;GCC;GCG;GGC;GGT;GTG;TAG;TCA;TCG;TCT;TGA;TGG;TTT	33.33333	24	0.583417	40	0.78195
0	32	ACC;AGA;CCA;CCG;CGA;CGC;CGG;CTA;CTC;GAG;GCG;GGT;TAG;TCA;TCG;TCT;TGA;TGG	33.33333	18	0.572333	46	0.814087
2500	32	ACC;CGA;CGC;GCG;GGT;TCA;TCG;TGA	50	8	0.6	56	0.837678
5000	32	CGA;TCG	100	2	0.636	62	0.853935
7500	32	CGA;CGC;GCG;TCG	100	4	0.5945	60	0.860033
0	33		0	0	NaN	64	0.871593

Предвиђена острва

Пример датотеке која предвиђа појављивање острва код изолата [Salmonella enterica subsp. enterica serovar Choleraesuis str. SC-B67](#). Атрибути представљају почетак, крај, дужину и врх региона који покрива геномско острво. Ови атрибути нису прецизне позиције предвиђених острва, већ позиције најмањих региона који их покривају





Почетак	Крај	Дужина	Врх Острва
330 000	357 500	27 500	340 000...350 000
370 000	417 500	47 500	375 000...385 000
1 512 500	1 530 000	17 500	1 512 500...1 527 500
1 730 000	1 745 000	15 000	1 730 000...1 745 000
1 967 500	1 992 500	25 000	1 967 500...1 977 500
2 180 000	2 197 500	17 500	2 180 000...2 192 500
2 240 000	2 257 500	17 500	2 242 500...2 252 500
2 962 500	2 985 000	22 500	2 972 500...2 982 500
4 410 000	4 427 500	17 500	4 410 000...4 420 000
4 645 000	4 667 500	22 500	4 645 000...4 662 500

Резултати

- Анализа ДА бројача
 - Понашање ДА бројача на прозорима са узастопним позитивним вредностима и анализа дужина ових региона
- Поређење добијених резултата
 - Поређење резултата са другим методама за идентификовање геномских острва
 - Утврђивање процента предвиђених патогених острва поређењем са подацима у PAI DB бази података
- Провера утицаја међусобне зависности геномских секвенци над којима је изграђен модел и оних које су коришћене за тестирање
- Идентификовање острва који се предвиђају само предложеном методом
- Провера зависности резултата од алата који је коришћен за класификацију

Анализа ДА бројача

Слика горе лево - Представљене вредности
ДА Бројача после извршене класификације
на прозорима дужине 10 Кбп и удаљењем
0 на изолату [Escherichia Coli APEC O1](#). За
класификацију је коришћен алгоритам C4.5,
а дужина n-грама је 3. Слика доле лево -
Идентификована острва на истом изолату
помоћу других метода за идентификовање
острва. Јединица означава присуство
острва, а нула да га нема. Слика горе десно
– Максималне вредности ДА Бројача на
групама прозора којесу кандидати за
острва. Слика доле десно – Дужине група
које су кандидати за острва. Поређењем
графикона може да се закључи да постоје
поклапања у предвиђеним и
идентификованим острвима за најдуже
низове узастопних позитивних вредности
ДА Бројача, као и за вредности овог
атрибута изнад одређене границе



Резултати класификације геномских острва код изолата фамилија Escherichia и Shigella

Поређење мера тачности за предвиђена геномска острва тестирањем различитих изолата фамилија Escherichia coli и Shigella. Модел је изграђен помоћу изолата Escherichia coli O157:H7 EDL933. У првој групи се налазе изолати врсте Escherichia coli, док се у другој групи налазе изолати врсте Shigella.

Назив генома		Приступни назив	Island Viewer			PAI DB		
			Прецизност	Одзив	F-мера	Прецизност	Одзив	F-мера
Escherichia coli K12		NC_000913	68.18%	68.75%	68.46%	9.09%	100%	16.66%
Escherichia coli 536		NC_008253	89.47%	78.38%	83.56%	-	-	
Escherichia coli O157:H7 str. Sakai		NC_002695	90.32%	83.05%	86.53%	12.9%	100%	22.85%
Escherichia coli UTI89		NC_007946	86.36%	71.74%	78.37%	-	-	
Escherichia coli W3110		AC_000091	83.33%	75%	78.94%	-	-	
Escherichia coli CFT073		NC_004431	90.47%	77.55%	83.51%	42.86%	84.61%	56.90%
Escherichia coli APEC 01		NC_008563	96.15%	84.31%	89.84%	-	-	
Просечна Вредност			86.32%	76.97%	81.37%	21.61%	94.87%	35.20%
Shigella flexneri 5 str. 8401		NC_008258	79.16%	56.81%	66.15%	-	-	
Shigella flexneri 2a str. 301		NC_004337	65.38%	55.26%	59.90%	23.08%	90.90%	36.81%
Shigella sonnei Ss046		NC_007384	89.47%	52.94%	66.52%	15.78%	100%	27.26%
Shigella boydii Sb227		NC_007613	65%	38.46%	48.32%	10%	100%	18.18%
Shigella dysenteriae Sd197		NC_007606	75%	35.14%	47.86%	12.5%	40%	19.05%
Shigella flexneri 2a str. 2457T		NC_004741	74.07%	58.54%	65.40%	6.75%	62.5%	12.18%
Просечна Вредност			74.68%	49.52%	59.55%	13.62%	78.68%	23.22%

Резултати – модел над више изолата

- Направљен је модел над два изолата врста *Salmonella* и *Xanthomonas*
- Модел је показао одређену правилност – геноми који су истих или сличних врста као они над којима је креиран модел су показали добре резултате (F-мера $\approx 80\%$)
- Геномске секвенце врсте *Yersinia* су показале лоше резултате над претходним моделом и за њих је направљен нови модел над геномском секвенцом исте врсте – *Yersinia pestis* CO2 (NC_003143) над којим су геномске секвенце ове врсте показале боље резултате

Поређење резултата различитих модела

Резултати класификације геномских секвенци реда *Yersinia* извршене над моделом који је изграђен помоћу два изолата: [Salmonella enterica subsp. enterica serovar Choleraesuis](#) SC-B67 (NC_006905) и генома [Xanthomonas campestris pv. Vesicatoria](#) str. 85-10 (NC_007508)

Назив генома	Скраћени назив	Прецизност	Одзив	F-мера
Yersinia pestis KIM	NC_004088	20.68%	68.18%	31.73%
Yersinia pseudotuberculosis IP 32953	NC_006155	29.09%	79.16%	42.54%
Yersinia pestis biovar Microtus str. 91001	NC_005810	18.51%	38.46%	24.99%

Резултати класификације геномских острва реда *Yersinia* извршене над моделом направљеним над једним изолатом истог реда - [Yersinia pestis CO92](#) (NC_003143)


Назив генома	Скраћени назив	Прецизност	Одзив	F-мера
Yersinia pestis KIM	NC_004088	88.88%	36.36%	51.61%
Yersinia pseudotuberculosis IP 32953	NC_006155	54.54%	29.16%	38.00%
Yersinia pestis biovar Microtus str. 91001	NC_005810	70.00%	30.76%	42.74%

Резултати - проналажење нових острва

Прозор који приказује регион изолата *Escherichia coli* O157:H7 str. Sakai (NC_002695) на позицији 800 – 820 Кбп. Идентификован је један покретни елемент - уметнута секвенца *IS677-4*



Прозор који приказује регион изолата *Escherichia coli* O157:H7 str. Sakai (NC_002695) на позицији 2152,5 – 2260 Кбп. Учено је више различитих геномских структура које указују на присуство геномског острва. Пронађени су региони трнаспоноване РНК и уметнутих секвенци *IS629-08*, *IS604-04* и *ISEc8-06*.



Програмски пакет

Genome Sequences Data Manager

- *GenomeSequencesDataManager* је програм који омогућава припрему података и обраду резултата у развијеној методи.
- Овај програм је направљен у програмском језику C# и подељен је у две целине са следећим функционалностима:
 - Припрема података за класификацију
 - Обрада геномских датотека и прављење датотека за унос
 - Операције са базом података
 - Статистичка обрада припремљених података
 - Обрада резултата

Додатак - програмски пакет Genome Sequences Data Manager

Главна форма
програмског пакета
Genome Sequences
Data Manager након
учитавања скупа
датотека са
информацијама о
геномима

Genome Sequences Data Manager

File Data Set Textual Files Database Ngram Help

Genome Files

Genome File Type: ☒ GenBank & Fasta ☐ Full GenBank

GenBank File: Browse Clear

Fasta File: Browse Clear

Genome Data Set

Add Genomes From Folder Add Genome Remove Genome Preview GenBank File Preview Fasta File

Textual Files

Delete Data Files Create Data Files

Database

Server: None Database: None

Status: Not Connected

Connect Drop Tables Create Tables Import Data

Order	Genome	GenBank File	GenBank File Type	GenBank File Size	Fasta File	Fasta File Size
1	AC_000091	AC_000091_sequence...	GenBank Full	98841175	-	-
2	AE005174	AE005174_sequences...	GenBank Full	13409886	-	-
3	NC_000913	NC_000913_sequence...	GenBank Full	13407410	-	-
4	NC_002655	NC_002655_sequence...	GenBank Full	13238606	-	-
5	NC_002695	NC_002695_sequence...	GenBank Full	12853041	-	-
6	NC_004337	NC_004337_sequence...	GenBank Full	10646270	-	-
7	NC_004431	NC_004431_sequence...	GenBank Full	13000997	-	-
8	NC_004741	NC_004741_sequence...	GenBank Full	11140080	-	-
9	NC_007384	NC_007384_sequence...	GenBank Full	11570550	-	-
10	NC_007606	NC_007606_sequence...	GenBank Full	10387313	-	-
11	NC_007613	NC_007613_sequence...	GenBank Full	10592798	-	-

Могућности за оптимизацију методе

- Проналажење другачијег услова за означавање неког прозора позитивним на присуство острва
- Испитивање утицаја величине прозора на тачност предвиђања
- Промена начина да се сви Н-грами на прозору који припада неком острву означе као позитивни, већ само неки који покажу специфично понашање
- Утврђивање доње границе која даје најбоља предвиђања за острва

Закључак

- Резултати показују висок проценат поклапања са другим методама за идентификовање острва
- Метода предвиђа постојање нових острва
- Алгоритам за класификацију C4.5 у комбинацији са триграмима најбоље решава постављени проблем
- Резултати зависе од сличности геномских секвенци
- Метода може да се користи за предвиђање патогених острва

Даљи рад

- Примена уочених могућности за оптимизацију
- Већа аутоматизација методе
- Примена методе за утврђивање геномских острва код виших организама
- Примена методе на идентификовање гена
- Проналажење начина да се метода примени на класификовање фамилија геномских секвенци
- Потврда и примена добијених резултата у даљим истраживањима